

# Identificación de Sistemas

Leandro Vignolo

Procesamiento Digital de Señales  
Ingeniería en Informática  
FICH-UNL

Abril de 2020

# Organización de la clase

## 1 Introducción

- Conceptos generales
- Aplicaciones
- Métodos de identificación de sistemas

## 2 Método de Predicción Lineal

- Predicción lineal
- Resolución del sistema de Wiener-Hopf
- Estimación del orden

## 3 Método adaptativo de Widrow

# Organización de la clase

## 1 Introducción


- Conceptos generales
- Aplicaciones
- Métodos de identificación de sistemas

## 2 Método de Predicción Lineal

- Predicción lineal
- Resolución del sistema de Wiener-Hopf
- Estimación del orden


## 3 Método adaptativo de Widrow

# ¿Qué significa identificar un sistema?



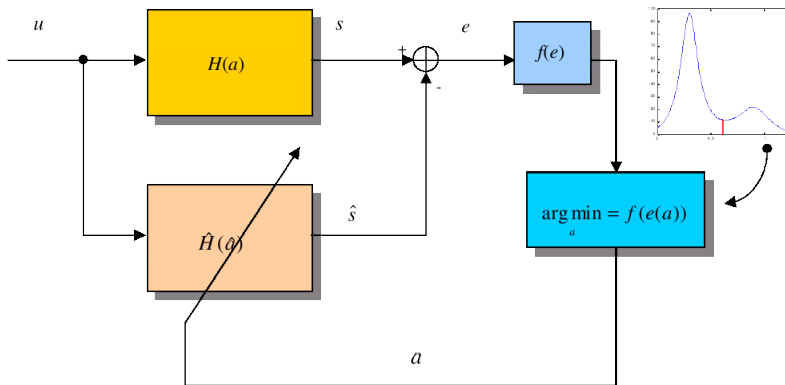
Encontrar un **modelo** y sus **parámetros**, en base a los datos de entrada y salida.

# ¿Qué significa identificar un sistema?



Encontrar un **modelo** y sus **parámetros**, en base a los datos de entrada y salida.

# Esquema general



# Aplicaciones

- Predicción
- Compresión
- Telefonía móvil
- Extracción de características
- etc.

# Identificación de sistemas

## Métodos convencionales

- Sistemas LTI
  - Análisis de la respuesta en sistemas continuos
  - Método de Predicción Lineal
- Métodos adaptativos

## Métodos no convencionales

- Técnicas de búsqueda y optimización



# Identificación de sistemas


## Métodos convencionales

- Sistemas LTI
  - Análisis de la respuesta en sistemas continuos
  - Método de Predicción Lineal
- Métodos adaptativos

## Métodos no convencionales

- Técnicas de búsqueda y optimización

## Análisis de la respuesta transitoria (escalón)


$$H(s) = \frac{k}{\zeta s + 1}$$
$$H(s) = \frac{k\omega^2}{s^2 + 2\xi\omega s + \omega^2}$$


Constante  $\zeta$ : tiempo que tarda el sistema en alcanzar el 63.7 % del valor final.

Relación de amortiguamiento  $\xi$



# Análisis de la respuesta en sistemas continuos

## Análisis de la respuesta transitoria (escalón)



1er orden:

$$H(s) = \frac{k}{\zeta s + 1}$$

2do orden:

$$H(s) = \frac{k\omega^2}{s^2 + 2\xi\omega s + \omega^2}$$

## Análisis de la respuesta en frecuencia

Desventajas de estos métodos:

- Dificultad en sistemas de alto orden
- Se requiere poder manipular la entrada del sistema

# Organización de la clase

## 1 Introducción

- Conceptos generales
- Aplicaciones
- Métodos de identificación de sistemas

## 2 Método de Predicción Lineal

- Predicción lineal
- Resolución del sistema de Wiener-Hopf
- Estimación del orden

## 3 Método adaptativo de Widrow

# Predicción lineal

## El modelo LTI más general

Modelo ARMA: predicción de la salida en el instante  $n$  a partir de salidas y entradas en instantes anteriores

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G \sum_{\ell=0}^q b_{\ell} u_{n-\ell}$$

$$H(z) = G \frac{1 + \sum_{\ell=1}^q b_{\ell} z^{-\ell}}{1 + \sum_{k=1}^p a_k z^{-k}}$$

# Predicción lineal

## El modelo LTI más general

Modelo ARMA: predicción de la salida en el instante  $n$  a partir de salidas y entradas en instantes anteriores

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G \sum_{\ell=0}^q b_{\ell} u_{n-\ell}$$

$$H(z) = G \frac{1 + \sum_{\ell=1}^q b_{\ell} z^{-\ell}}{1 + \sum_{k=1}^p a_k z^{-k}}$$

# Simplificaciones iniciales

Modelo Auto Regresivo:

$$H(z) = G \frac{B(z)}{A(z)} \approx \frac{G}{C(z)}$$

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n$$

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$



# Simplificaciones iniciales

Modelo Auto Regresivo:

$$H(z) = \frac{G}{1 + \sum_{k=1}^p a_k z^{-k}}$$

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n$$

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

# Simplificaciones iniciales

Modelo Auto Regresivo:

$$H(z) = \frac{G}{1 + \sum_{k=1}^p a_k z^{-k}}$$

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n$$

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

# Simplificaciones iniciales

Modelo Auto Regresivo:

$$H(z) = \frac{G}{1 + \sum_{k=1}^p a_k z^{-k}}$$

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n$$

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

# Notación vectorial...

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_k \\ \vdots \\ a_p \end{bmatrix} \quad \mathbf{s}_n = \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-k} \\ \vdots \\ s_{n-p} \end{bmatrix}$$

$$\hat{s}_n = -\mathbf{s}_n^T \mathbf{a}$$

# Notación vectorial...

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_k \\ \vdots \\ a_p \end{bmatrix} \quad \mathbf{s}_n = \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-k} \\ \vdots \\ s_{n-p} \end{bmatrix}$$

$$\hat{s}_n = -\mathbf{s}_n^T \mathbf{a}$$

# Notación vectorial...

$$\hat{s}_n = - \sum_{k=1}^p a_k s_{n-k}$$

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_k \\ \vdots \\ a_p \end{bmatrix} \quad \mathbf{s}_n = \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-k} \\ \vdots \\ s_{n-p} \end{bmatrix}$$

$$\hat{s}_n = -\mathbf{s}_n^T \mathbf{a}$$

# Cuadrados Mínimos

## Minimización del error cuadrático / señales determinísticas

Podemos usar una medida del error instantáneo para minimizar el error entre  $s_n$  y  $\hat{s}_n$ :

$$e_n^2 = (s_n - \hat{s}_n)^2 = (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Minimizar  $e_n$  en todo el proceso - Error Cuadrático Total:

$$\xi^2 = \sum_n e_n^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Para encontrar el mínimo:

$$\nabla_{\mathbf{a}} \xi^2 = 0$$

# Cuadrados Mínimos

## Minimización del error cuadrático / señales determinísticas

Podemos usar una medida del error instantáneo para minimizar el error entre  $s_n$  y  $\hat{s}_n$ :

$$e_n^2 = (s_n - \hat{s}_n)^2 = (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Minimizar  $e_n$  en todo el proceso - Error Cuadrático Total:

$$\xi^2 = \sum_n e_n^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Para encontrar el mínimo:

$$\nabla_{\mathbf{a}} \xi^2 = 0$$



# Cuadrados Mínimos

## Minimización del error cuadrático / señales determinísticas

Podemos usar una medida del error instantáneo para minimizar el error entre  $s_n$  y  $\hat{s}_n$ :

$$e_n^2 = (s_n - \hat{s}_n)^2 = (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Minimizar  $e_n$  en todo el proceso - Error Cuadrático Total:

$$\xi^2 = \sum_n e_n^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

Para encontrar el mínimo:

$$\nabla_{\mathbf{a}} \xi^2 = 0$$

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2 \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n^2 + 2\mathbf{a}^T s_n \mathbf{s}_n + \mathbf{a}^T s_n \mathbf{s}_n^T \mathbf{a}) \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n s_n^2 \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n 2\mathbf{a}^T s_n \mathbf{s}_n \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n \mathbf{a}^T s_n \mathbf{s}_n^T \mathbf{a} \right\}$$

$$0 = 0 + 2 \sum_n s_n \mathbf{s}_n + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a}$$

$$\sum_n s_n \mathbf{s}_n^T \mathbf{a} = - \sum_n s_n \mathbf{s}_n$$

Sistema de  $p$  ecuaciones con  $p$  incógnitas (ecuaciones normales).

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2 \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n^2 + 2\mathbf{a}^T s_n \mathbf{s}_n + \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}) \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n s_n^2 \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n 2\mathbf{a}^T s_n \mathbf{s}_n \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} \right\}$$

$$0 = 0 + 2 \sum_n s_n \mathbf{s}_n + 2 \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} = - \sum_n s_n \mathbf{s}_n$$

Sistema de  $p$  ecuaciones con  $p$  incógnitas (ecuaciones normales).

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2 \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n^2 + 2\mathbf{a}^T s_n \mathbf{s}_n + \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}) \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n s_n^2 \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n 2\mathbf{a}^T s_n \mathbf{s}_n \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} \right\}$$

$$0 = 0 + 2 \sum_n s_n \mathbf{s}_n + 2 \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} = - \sum_n s_n \mathbf{s}_n$$

Sistema de  $p$  ecuaciones con  $p$  incógnitas (ecuaciones normales).

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2 \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n^2 + 2\mathbf{a}^T s_n \mathbf{s}_n + \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}) \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n s_n^2 \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n 2\mathbf{a}^T s_n \mathbf{s}_n \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} \right\}$$

$$0 = 0 + 2 \sum_n s_n \mathbf{s}_n + 2 \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} = - \sum_n s_n \mathbf{s}_n$$

Sistema de  $p$  ecuaciones con  $p$  incógnitas (ecuaciones normales).

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2 \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n (s_n^2 + 2\mathbf{a}^T s_n \mathbf{s}_n + \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}) \right\}$$

$$0 = \nabla_{\mathbf{a}} \left\{ \sum_n s_n^2 \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n 2\mathbf{a}^T s_n \mathbf{s}_n \right\} + \nabla_{\mathbf{a}} \left\{ \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} \right\}$$

$$0 = 0 + 2 \sum_n s_n \mathbf{s}_n + 2 \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a} = - \sum_n s_n \mathbf{s}_n$$

Sistema de  $p$  ecuaciones con  $p$  incógnitas (ecuaciones normales).

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

## Sistema de ecuaciones de Wiener-Hopf:

$$\left( \sum_n \mathbf{s}_n \mathbf{s}_n^T \right) \mathbf{a} = - \sum_n \mathbf{s}_n s_n$$

con:

$$\mathbf{R} = \sum_n \mathbf{s}_n \mathbf{s}_n^T \quad y \quad \mathbf{r} = \sum_n \mathbf{s}_n s_n$$

$$\mathbf{R} \mathbf{a} = -\mathbf{r}$$

# Cuadrados Mínimos

Minimización del error cuadrático / señales determinísticas

## Sistema de ecuaciones de Wiener-Hopf:

$$\left( \sum_n \mathbf{s}_n \mathbf{s}_n^T \right) \mathbf{a} = - \sum_n \mathbf{s}_n s_n$$

con:

$$\mathbf{R} = \sum_n \mathbf{s}_n \mathbf{s}_n^T \quad y \quad \mathbf{r} = \sum_n \mathbf{s}_n s_n$$

$$\mathbf{R} \mathbf{a} = -\mathbf{r}$$



# Autocorrelación

## Señales aleatorias

Correlación cruzada:

$$R_{xy}(i, j) = \mathcal{E}\{x[n + i]y^*[n + j]\}$$

# Autocorrelación

## Señales aleatorias

Correlación cruzada:

$$R_{xy}(i, j) = \mathcal{E}\{x[n + i]y^*[n + j]\}$$

Autocorrelación:

$$R_s(i, j) = \mathcal{E}\{s[n + i]s^*[n + j]\}$$

# Autocorrelación

## Señales aleatorias

Correlación cruzada:

$$R_{xy}(i, j) = \mathcal{E}\{x[n + i]y^*[n + j]\}$$

Autocorrelación:

$$R_s(i, j) = \mathcal{E}\{s[n + i]s^*[n + j]\}$$

Matriz de autocorrelación:

$$\mathbf{R}_s = \begin{bmatrix} R_s(0, 0) & R_s(0, 1) & R_s(0, 2) & \dots & R_s(0, N - 1) \\ R_s(1, 0) & R_s(1, 1) & R_s(1, 2) & \dots & R_s(1, N - 1) \\ R_s(2, 0) & R_s(2, 1) & R_s(2, 2) & \dots & R_s(2, N - 1) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ R_s(N - 1, 0) & R_s(N - 1, 1) & R_s(N - 1, 2) & \dots & R_s(N - 1, N - 1) \end{bmatrix}$$

# Autocorrelación

Señales determinísticas: la  $\mathcal{E}$  pasa a ser  $\sum$  y sólo depende del desplazamiento relativo  $(i - j) \rightarrow R_s(i, j) = r_s(i - j)$

$$r_s(i) = \sum_{n=-\infty}^{\infty} s[n]s^*[n+i]$$

# Autocorrelación

**Señales determinísticas:** la  $\mathcal{E}$  pasa a ser  $\sum$  y sólo depende del desplazamiento relativo  $(i - j) \rightarrow R_s(i, j) = r_s(i - j)$

$$r_s(i) = \sum_{n=-\infty}^{\infty} s[n]s^*[n+i]$$

$$\mathbf{R}_s = \begin{bmatrix} r_s(0) & r_s(-1) & r_s(-2) & \dots & r_s(-N+1) \\ r_s(1) & r_s(0) & r_s(-1) & \dots & r_s(-N+2) \\ r_s(2) & r_s(1) & r_s(0) & \dots & r_s(-N+3) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_s(N-1) & r_s(N-2) & \dots & \dots & r_s(0) \end{bmatrix}$$

# Autocorrelación

**Señales determinísticas:** la  $\mathcal{E}$  pasa a ser  $\sum$  y sólo depende del desplazamiento relativo  $(i - j) \rightarrow R_s(i, j) = r_s(i - j)$

$$r_s(i) = \sum_{n=-\infty}^{\infty} s[n]s^*[n+i]$$

$$\mathbf{R}_s = \begin{bmatrix} r_s(0) & r_s(-1) & r_s(-2) & \dots & r_s(-N+1) \\ r_s(1) & r_s(0) & r_s(-1) & \dots & r_s(-N+2) \\ r_s(2) & r_s(1) & r_s(0) & \dots & r_s(-N+3) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_s(N-1) & r_s(N-2) & \dots & \dots & r_s(0) \end{bmatrix}$$

Notar que además  $r_s(-i) = r_s(i) \dots$

# Autocorrelación

**Señales determinísticas:** la  $\mathcal{E}$  pasa a ser  $\sum$  y sólo depende del desplazamiento relativo  $(i - j) \rightarrow R_s(i, j) = r_s(i - j)$

$$r_s(i) = \sum_{n=-\infty}^{\infty} s[n]s^*[n+i]$$

$$\mathbf{R}_s = \begin{bmatrix} r_s(0) & r_s(1) & r_s(2) & \dots & \dots & r_s(N-1) \\ r_s(1) & r_s(0) & r_s(1) & \dots & \dots & r_s(N-2) \\ r_s(2) & r_s(1) & r_s(0) & \dots & \dots & r_s(N-3) \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ r_s(N-2) & \dots & \dots & \dots & r_s(0) & r_s(1) \\ r_s(N-1) & r_s(N-2) & \dots & \dots & r_s(1) & r_s(0) \end{bmatrix}$$

$\mathbf{R}_s$  es **simétrica** y **Toeplitz**.

# Sistema de Wiener-Hopf

## Matriz y vector de autocorrelación

$$\left( \sum_n \mathbf{s}_n \mathbf{s}_n^T \right) \mathbf{a} = - \sum_n \mathbf{s}_n s_n$$

$$\mathbf{s}_n = \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix}$$

$$\sum_n s_n \mathbf{s}_n = \sum_n s_n \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix} = \begin{bmatrix} \sum_n s_{n-1} s_n \\ \sum_n s_{n-2} s_n \\ \vdots \\ \sum_n s_{n-p} s_n \end{bmatrix} = \begin{bmatrix} r_s(1) \\ r_s(2) \\ \vdots \\ r_s(p) \end{bmatrix} = \mathbf{r}$$



# Sistema de Wiener-Hopf

## Matriz y vector de autocorrelación

$$\left( \sum_n \mathbf{s}_n \mathbf{s}_n^T \right) \mathbf{a} = - \sum_n \mathbf{s}_n s_n$$

$$\mathbf{s}_n = \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix}$$

$$\sum_n s_n \mathbf{s}_n = \sum_n s_n \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix} = \begin{bmatrix} \sum_n s_{n-1} s_n \\ \sum_n s_{n-2} s_n \\ \vdots \\ \sum_n s_{n-p} s_n \end{bmatrix} = \begin{bmatrix} r_s(1) \\ r_s(2) \\ \vdots \\ r_s(p) \end{bmatrix} = \mathbf{r}$$

# Sistema de Wiener-Hopf

## Matriz y vector de autocorrelación

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T = \sum_n \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix} [s_{n-1}, s_{n-2}, \dots, s_{n-p}] =$$

$$\sum_n \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & \dots & s_{n-1}s_{n-p} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & \dots & s_{n-2}s_{n-p} \\ \vdots & \vdots & \dots & \vdots \\ s_{n-p}s_{n-1} & s_{n-p}s_{n-2} & \dots & s_{n-p}s_{n-p} \end{bmatrix} = \mathbf{R}_s$$

# Sistema de Wiener-Hopf

## Matriz y vector de autocorrelación

$$\sum_n \mathbf{s}_n \mathbf{s}_n^T = \sum_n \begin{bmatrix} s_{n-1} \\ s_{n-2} \\ \vdots \\ s_{n-p} \end{bmatrix} [s_{n-1}, s_{n-2}, \dots, s_{n-p}] =$$

$$\sum_n \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & \dots & s_{n-1}s_{n-p} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & \dots & s_{n-2}s_{n-p} \\ \vdots & \vdots & \dots & \vdots \\ s_{n-p}s_{n-1} & s_{n-p}s_{n-2} & \dots & s_{n-p}s_{n-p} \end{bmatrix} = \mathbf{R}_s$$

# Sistema de Wiener-Hopf

## Rango de la sumatoria

Ejemplo: un sistema de orden  $P = 3$

$$\mathbf{R}_s = \sum_{n=?}^? \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & s_{n-1}s_{n-3} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & s_{n-2}s_{n-3} \\ s_{n-3}s_{n-1} & s_{n-3}s_{n-2} & s_{n-3}s_{n-3} \end{bmatrix},$$

# Sistema de Wiener-Hopf

## Rango de la sumatoria

Ejemplo: un sistema de orden  $P = 3$

$$\mathbf{R}_s = \sum_{n=?}^? \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & s_{n-1}s_{n-3} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & s_{n-2}s_{n-3} \\ s_{n-3}s_{n-1} & s_{n-3}s_{n-2} & s_{n-3}s_{n-3} \end{bmatrix},$$

Si sumamos  $n = 1 \dots 3$

$$\mathbf{R}_s = \begin{bmatrix} s_0s_0 + s_1s_1 + s_2s_2 & s_0s_{-1} + s_1s_0 + s_2s_1 & s_0s_{-2} + s_1s_{-1} + s_2s_0 \\ s_{-1}s_0 + s_0s_1 + s_1s_2 & s_{-1}s_{-1} + s_0s_0 + s_1s_1 & s_{-1}s_{-2} + s_0s_{-1} + s_1s_0 \\ s_{-2}s_0 + s_{-1}s_1 + s_0s_2 & s_{-2}s_{-1} + s_{-1}s_0 + s_0s_1 & s_{-2}s_{-2} + s_{-1}s_{-1} + s_0s_0 \end{bmatrix}$$

$R_s$  es simétrica pero no es Toeplitz.

Método de Covariancia: intervalo finito

# Sistema de Wiener-Hopf

## Rango de la sumatoria

Ejemplo: un sistema de orden  $P = 3$

$$\mathbf{R}_s = \sum_{n=?}^? \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & s_{n-1}s_{n-3} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & s_{n-2}s_{n-3} \\ s_{n-3}s_{n-1} & s_{n-3}s_{n-2} & s_{n-3}s_{n-3} \end{bmatrix},$$

Si  $s_n \neq 0$  sólo para  $n = 1 \dots 3$  y sumamos desde  $-\infty$  hasta  $\infty$ :

$$r_{1,1} = \sum_{-\infty}^{\infty} s_{n-1}s_{n-1} = \dots s_{-1}s_{-1} + s_0s_0 + s_1s_1 + s_2s_2 + s_3s_3 + s_4s_4 + s_5s_5 + \dots$$

# Sistema de Wiener-Hopf

## Rango de la sumatoria

Ejemplo: un sistema de orden  $P = 3$

$$\mathbf{R}_s = \sum_{n=?}^? \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & s_{n-1}s_{n-3} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & s_{n-2}s_{n-3} \\ s_{n-3}s_{n-1} & s_{n-3}s_{n-2} & s_{n-3}s_{n-3} \end{bmatrix},$$

Si  $s_n \neq 0$  sólo para  $n = 1 \dots 3$  y sumamos desde  $-\infty$  hasta  $\infty$ :

$$\mathbf{R}_s = \begin{bmatrix} s_1s_1 + s_2s_2 + s_3s_3 & s_2s_1 + s_3s_2 & s_3s_1 \\ s_1s_2 + s_2s_3 & s_1s_1 + s_2s_2 + s_3s_3 & s_2s_1 + s_3s_2 \\ s_1s_3 & s_1s_2 + s_2s_3 & s_1s_1 + s_2s_2 + s_3s_3 \end{bmatrix}$$

# Sistema de Wiener-Hopf

## Rango de la sumatoria

Ejemplo: un sistema de orden  $P = 3$

$$\mathbf{R}_s = \sum_{n=?}^? \begin{bmatrix} s_{n-1}s_{n-1} & s_{n-1}s_{n-2} & s_{n-1}s_{n-3} \\ s_{n-2}s_{n-1} & s_{n-2}s_{n-2} & s_{n-2}s_{n-3} \\ s_{n-3}s_{n-1} & s_{n-3}s_{n-2} & s_{n-3}s_{n-3} \end{bmatrix},$$

Si  $s_n \neq 0$  sólo para  $n = 1 \dots 3$  y sumamos desde  $-\infty$  hasta  $\infty$ :

$$\mathbf{R}_s = \begin{bmatrix} s_1s_1 + s_2s_2 + s_3s_3 & s_2s_1 + s_3s_2 & s_3s_1 \\ s_1s_2 + s_2s_3 & s_1s_1 + s_2s_2 + s_3s_3 & s_2s_1 + s_3s_2 \\ s_1s_3 & s_1s_2 + s_2s_3 & s_1s_1 + s_2s_2 + s_3s_3 \end{bmatrix}$$

$\mathbf{R}_s$  es simétrica y Toeplitz.

Sólo necesitamos sumar  $2N - 1$  términos.

Método de Correlación: intervalo “infinito”



# Señales aleatorias

En el caso de señales **aleatorias** debemos considerar el valor **esperado** del error instantáneo:

$$\xi^2 = \mathcal{E} [e_n^2] = \mathcal{E} [s_n^2] + \mathbf{a}^T 2\mathcal{E} [s_n \mathbf{s}_n] + \mathbf{a}^T \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a}$$

$$\nabla_{\mathbf{a}} \xi^2 = 0 \longrightarrow \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a} = -\mathcal{E} [s_n \mathbf{s}_n]$$

Autocorrelación (señales aleatorias):  $R_s(i, j) = \mathcal{E} \{s[n+i]s^*[n+j]\}$

## Señales estacionarias:

La matriz de correlación  $\mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] = \mathbf{R}$  es simétrica y Toeplitz, como en el caso de señales determinísticas.

## Señales localmente estacionarias.

# Señales aleatorias

En el caso de señales **aleatorias** debemos considerar el valor **esperado** del error instantáneo:

$$\xi^2 = \mathcal{E} [e_n^2] = \mathcal{E} [s_n^2] + \mathbf{a}^T 2\mathcal{E} [s_n \mathbf{s}_n] + \mathbf{a}^T \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a}$$

$$\nabla_{\mathbf{a}} \xi^2 = 0 \longrightarrow \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a} = -\mathcal{E} [s_n \mathbf{s}_n]$$

Autocorrelación (señales aleatorias):  $R_s(i, j) = \mathcal{E}\{s[n+i]s^*[n+j]\}$

## Señales estacionarias:

La matriz de correlación  $\mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] = \mathbf{R}$  es simétrica y Toeplitz, como en el caso de señales determinísticas.

## Señales localmente estacionarias.

# Señales aleatorias

En el caso de señales **aleatorias** debemos considerar el valor **esperado** del error instantáneo:

$$\xi^2 = \mathcal{E} [e_n^2] = \mathcal{E} [s_n^2] + \mathbf{a}^T 2\mathcal{E} [s_n \mathbf{s}_n] + \mathbf{a}^T \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a}$$

$$\nabla_{\mathbf{a}} \xi^2 = 0 \longrightarrow \mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] \mathbf{a} = -\mathcal{E} [s_n \mathbf{s}_n]$$

Autocorrelación (señales aleatorias):  $R_s(i, j) = \mathcal{E}\{s[n+i]s^*[n+j]\}$

## Señales estacionarias:

La matriz de correlación  $\mathcal{E} [\mathbf{s}_n \mathbf{s}_n^T] = \mathbf{R}$  es simétrica y Toeplitz, como en el caso de señales determinísticas.

## Señales **localmente estacionarias**.

# Resolución del sistema de Wiener-Hopf

## Algoritmo de Levinson-Durbin

$$E_0 = r_0$$

$$\text{Para } 1 \leq i \leq p \rightarrow \begin{cases} k_i = -\frac{1}{E_{i-1}} \left[ r_i + \sum_{j=1}^{i-1} a_{j,i-1} r_{i-j} \right] \\ a_{i,i} = k_i \\ a_{j,i} = a_{j,i-1} + k_i a_{i-j,i-1}, \quad 1 \leq j \leq i-1 \\ E_i = E_{i-1}(1 - k_i^2) \end{cases}$$

Coeficientes  $a_{ij}$ :

$$\mathbf{A} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} & \dots & a_{1,p} \\ 0 & a_{2,2} & a_{2,3} & \dots & a_{2,p} \\ 0 & 0 & a_{3,3} & \vdots & \vdots \\ 0 & 0 & 0 & \ddots & \\ 0 & 0 & 0 & \dots & a_{p,p} \end{bmatrix}$$

# Resolución del sistema de Wiener-Hopf

## Algoritmo de Levinson-Durbin

$$E_0 = r_0$$

$$\text{Para } 1 \leq i \leq p \rightarrow \begin{cases} k_i = -\frac{1}{E_{i-1}} \left[ r_i + \sum_{j=1}^{i-1} a_{j,i-1} r_{i-j} \right] \\ a_{i,i} = k_i \\ a_{j,i} = a_{j,i-1} + k_i a_{i-j,i-1}, \quad 1 \leq j \leq i-1 \\ E_i = E_{i-1}(1 - k_i^2) \end{cases}$$

Coeficientes  $a_{ij}$ :

$$\mathbf{A} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} & \dots & a_{1,p} \\ 0 & a_{2,2} & a_{2,3} & \dots & a_{2,p} \\ 0 & 0 & a_{3,3} & \vdots & \vdots \\ 0 & 0 & 0 & \ddots & \\ 0 & 0 & 0 & \dots & a_{p,p} \end{bmatrix}$$

# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n,$$

# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n, \quad \text{si } u_n = \delta_n \rightarrow h_n = - \sum_{k=1}^p a_k h_{n-k} + G \delta_n,$$

# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n, \quad \text{si } u_n = \delta_n \rightarrow h_n = - \sum_{k=1}^p a_k h_{n-k} + G \delta_n,$$

Si multiplicamos por  $h_n$  y sumamos para  $n$ :

$$\sum_n h_n h_n = - \sum_n h_n \sum_k a_k h_{n-k} + \sum_n h_n G \delta_n,$$



# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n, \quad \text{si } u_n = \delta_n \rightarrow h_n = - \sum_{k=1}^p a_k h_{n-k} + G \delta_n,$$

Si multiplicamos por  $h_n$  y sumamos para  $n$ :

$$\sum_n h_n h_n = - \sum_n h_n \sum_k a_k h_{n-k} + \sum_n h_n G \delta_n,$$

$$\sum_n h_n h_n = - \sum_k a_k \sum_n h_n h_{n-k} + G \sum_n h_n \delta_n,$$

# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n, \quad \text{si } u_n = \delta_n \rightarrow h_n = - \sum_{k=1}^p a_k h_{n-k} + G \delta_n,$$

Si multiplicamos por  $h_n$  y sumamos para  $n$ :

$$\sum_n h_n h_n = - \sum_n h_n \sum_k a_k h_{n-k} + \sum_n h_n G \delta_n,$$

$$\sum_n h_n h_n = - \sum_k a_k \sum_n h_n h_{n-k} + G \sum_n h_n \delta_n,$$

$$r_0 = - \sum_k a_k r_k + G^2,$$

# Determinación de la constante de ganancia $G$

Modelo AR:

$$s_n = - \sum_{k=1}^p a_k s_{n-k} + G u_n, \quad \text{si } u_n = \delta_n \rightarrow h_n = - \sum_{k=1}^p a_k h_{n-k} + G \delta_n,$$

Si multiplicamos por  $h_n$  y sumamos para  $n$ :

$$\sum_n h_n h_n = - \sum_n h_n \sum_k a_k h_{n-k} + \sum_n h_n G \delta_n,$$

$$\sum_n h_n h_n = - \sum_k a_k \sum_n h_n h_{n-k} + G \sum_n h_n \delta_n,$$

$$r_0 = - \sum_k a_k r_k + G^2,$$

lo que demuestra que:

$$G^2 = \mathbf{r}^T \mathbf{a} + r_0.$$

# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2\mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2$$

→

$$G = \sqrt{E_p}$$

# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2 \mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2 \mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2 \mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2$$

→

$$G = \sqrt{E_p}$$

# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2 \mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2 \mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2 \mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2$$

→

$$G = \sqrt{E_p}$$

# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2\mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2$$

→

$$G = \sqrt{E_p}$$

# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2\mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2$$

→

$$G = \sqrt{E_p}$$



# Determinación de la constante de ganancia $G$

Recordemos la expresión del Error Cuadrático Total:

$$E_p = \sum_n (s_n - \hat{s}_n)^2 = \sum_n (s_n + \mathbf{s}_n^T \mathbf{a})^2$$

$$E_p = \sum_n s_n^2 + 2 \sum_n s_n \mathbf{s}_n^T \mathbf{a} + \sum_n \mathbf{a}^T \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = \sum_n s_n^2 + 2\mathbf{a}^T \sum_n s_n \mathbf{s}_n + \mathbf{a}^T \sum_n \mathbf{s}_n \mathbf{s}_n^T \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} + \mathbf{a}^T \mathbf{R} \mathbf{a}$$

$$E_p = r_0 + 2\mathbf{a}^T \mathbf{r} - \mathbf{a}^T \mathbf{r}$$

$$\boxed{E_p = r_0 + \mathbf{a}^T \mathbf{r} = G^2} \quad \rightarrow \quad \boxed{G = \sqrt{E_p}}$$

# Estimación del orden

## Error de predicción final

$E_p$  decrece monótonamente con  $p$ .

¿Cuál es el  $p$  óptimo?

Definimos el error normalizado como:

$$V_p = \frac{E_p}{r_0}$$

Definimos un umbral  $\gamma$  e incrementamos  $p$  hasta satisfacer:

$$1 - \frac{V_{p+1}}{V_p} < \gamma$$

# Estimación del orden

## Error de predicción final

$E_p$  decrece monótonamente con  $p$ .

¿Cuál es el  $p$  óptimo?

Definimos el error normalizado como:

$$V_p = \frac{E_p}{r_0}$$

Definimos un umbral  $\gamma$  e incrementamos  $p$  hasta satisfacer:

$$1 - \frac{V_{p+1}}{V_p} < \gamma$$

# Estimación del orden

## Criterio de Akaike


Basado en teoría de la información define:

$$I_p = \log E_p + \frac{2p}{N_e}$$

$$N_e = \frac{E_w}{E_r} N.$$

Este criterio provee un mínimo en el  $p$  óptimo.

# Estimación del orden: comparación



# Organización de la clase

## 1 Introducción

- Conceptos generales
- Aplicaciones
- Métodos de identificación de sistemas

## 2 Método de Predicción Lineal

- Predicción lineal
- Resolución del sistema de Wiener-Hopf
- Estimación del orden

## 3 Método adaptativo de Widrow

# Método adaptativo de Widrow

Consideremos  $s_n$  no-estacionaria y volvamos al error cuadrático instantáneo:

$$e_n^2 = (s_n - \hat{s}_n)^2 = (s_n + \mathbf{s}_n^T \mathbf{a})^2 = \xi_n^2$$

Tenemos que buscar el mínimo en cada instante  $n$ :

$$\mathbf{a}_{n+1} = \mathbf{a}_n + \mu(-\nabla \xi_n^2)$$

(método de Newton)

# Método adaptativo de Widrow

Consideremos  $s_n$  no-estacionaria y volvamos al error cuadrático instantáneo:

$$e_n^2 = (s_n - \hat{s}_n)^2 = (s_n + \mathbf{s}_n^T \mathbf{a})^2 = \xi_n^2$$

Tenemos que buscar el mínimo en cada instante  $n$ :

$$\mathbf{a}_{n+1} = \mathbf{a}_n + \mu(-\nabla \xi_n^2)$$

(método de Newton)



# Método adaptativo de Widrow

$$\hat{\nabla} \xi_n^2 = \frac{\partial e_n^2}{\partial \mathbf{a}_n} = 2e_n \frac{\partial (s_n + \mathbf{a}_n^T \mathbf{s}_n)}{\partial \mathbf{a}_n} = 2e_n \mathbf{s}_n$$

# Método adaptativo de Widrow

$$\hat{\nabla} \xi_n^2 = \frac{\partial e_n^2}{\partial \mathbf{a}_n} = 2e_n \frac{\partial (s_n + \mathbf{a}_n^T \mathbf{s}_n)}{\partial \mathbf{a}_n} = 2e_n \mathbf{s}_n$$

$$\mathbf{a}_{n+1} = \mathbf{a}_n - 2\mu e_n \mathbf{s}_n$$

donde  $\mathbf{a}_0$  se inicializa en  $[-0,5, 0,5]$  y  $0 < \mu < \frac{1}{T(\mathbf{R})}$


# Método adaptativo de Widrow

$$\hat{\nabla} \xi_n^2 = \frac{\partial e_n^2}{\partial \mathbf{a}_n} = 2e_n \frac{\partial (s_n + \mathbf{a}_n^T \mathbf{s}_n)}{\partial \mathbf{a}_n} = 2e_n \mathbf{s}_n$$


$$\mathbf{a}_{n+1} = \mathbf{a}_n - 2\mu e_n \mathbf{s}_n$$

$$\mathbf{A} = [\mathbf{a}_0, \mathbf{a}_1, \dots, \mathbf{a}_N] = \begin{bmatrix} a_{0,0} & a_{0,1} & \dots & a_{0,N} \\ a_{1,0} & a_{1,1} & \dots & a_{1,N} \\ \vdots & \vdots & \vdots & \vdots \\ a_{p,0} & a_{p,1} & \dots & a_{p,N} \end{bmatrix}$$


# Método adaptativo de Widrow




# Método adaptativo de Widrow



# Método adaptativo de Widrow



# Método adaptativo de Widrow



# Bibliografía

- J. Makhoul, “Linear Prediction: A Tutorial Review”, Proc. IEEE, volumen 63, no. 4, páginas 561-580, 1975.
- L. R. Rabiner y B. Gold, Theory and Application of Digital Signal Processing, Prentice Hall, 1975. Capítulo 12.
- J. R. Deller, J. G. Proakis, J. H. Hansen, Discrete-Time Processing of Speech Signals, Prentice Hall, 1993. Capítulo 5.
- C. W. Therrien, Discrete Random Signals and Statistical Signal Processing, Prentice Hall, 1992. Capítulos 4 y 8.
- J. G. Proakis y D. G. Manolakis, Tratamiento digital de señales, 3ra edición, 1998. Capítulo 11.